

Krystian Szczesny, krystian.szczesny@o2.pl

Analiza VAR

Wstęp

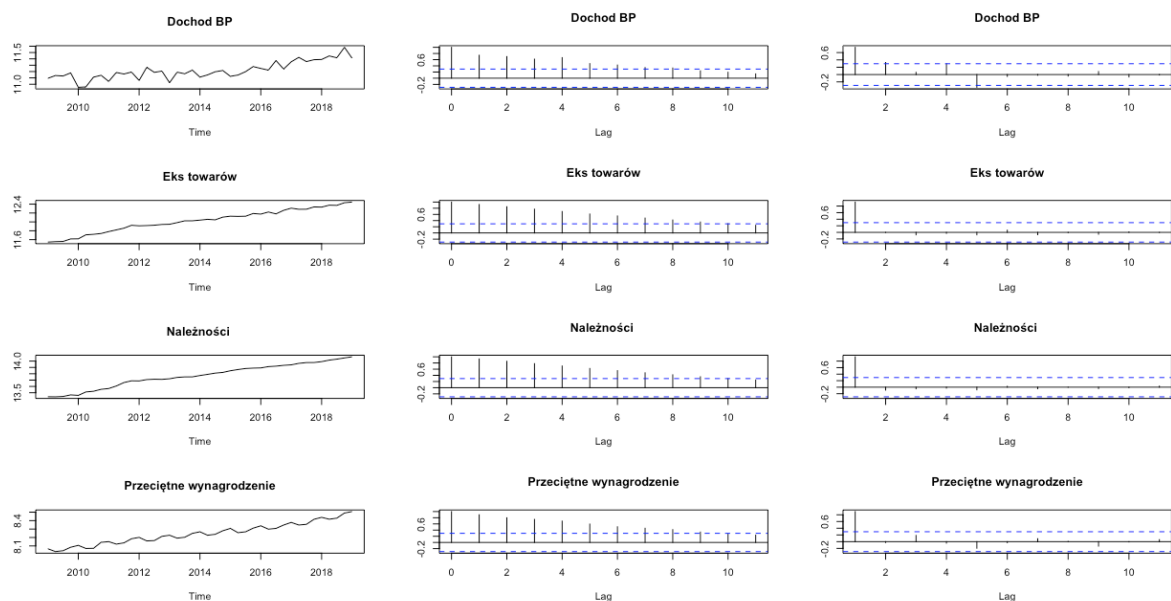
Celem projektu jest budowa modelu wektorowej autoregresji (VAR - Vector autoregression model). Model ten nie posiada podziału na zmienne egzogeniczne oraz endogeniczne, dzięki temu każda zmienna ma wpływ na pozostałe zmienne a proces modelowania dotyczy każdej zmiennej. Wybrane zmienne do modelowania w badaniu to:

- x1 (dochody budżetu państwa w mln zł) – spodziewa się, iż ich wzrost będzie przekładał się na wzrost dochodów przedsiębiorstw, ponieważ bogatszy budżet państwa wiąże się z dotacjami, obniżkami podatków oraz sprzyjającymi innymi działaniami ze strony państwa dla rozwoju przedsiębiorstw.
- x2 (eksport towarów ogółem w mln zł)
Export z kraju poza granice to sprzedaż towarów wyprodukowanych przez nasze przedsiębiorstwa a zatem zbyt i powiększające się ich dochody,
- x3 (należności ogółem w mln zł)
Należności to zobowiązania, które muszą być uregulowane i one osłabiają pozycje przedsiębiorstwa.
- X4 (przeciętne wynagrodzenie brutto)
Wzrost wynagrodzeń to wydajniejsza praca kadry pracowniczej, lepsza jej motywacja i silniejsze związanie się pracowników się z firmą. Są to czynniki wpływające pozytywnie na rozwój form.

Źródło danych:

<https://stat.gov.pl/wskazniki-makroekonomiczne/>

Przed przystąpieniem do analizy wszystkie zmienne zostały z logarytmowe. Poniżej prezentuje wykresy szeregów czasowych oraz ACF i PACF.

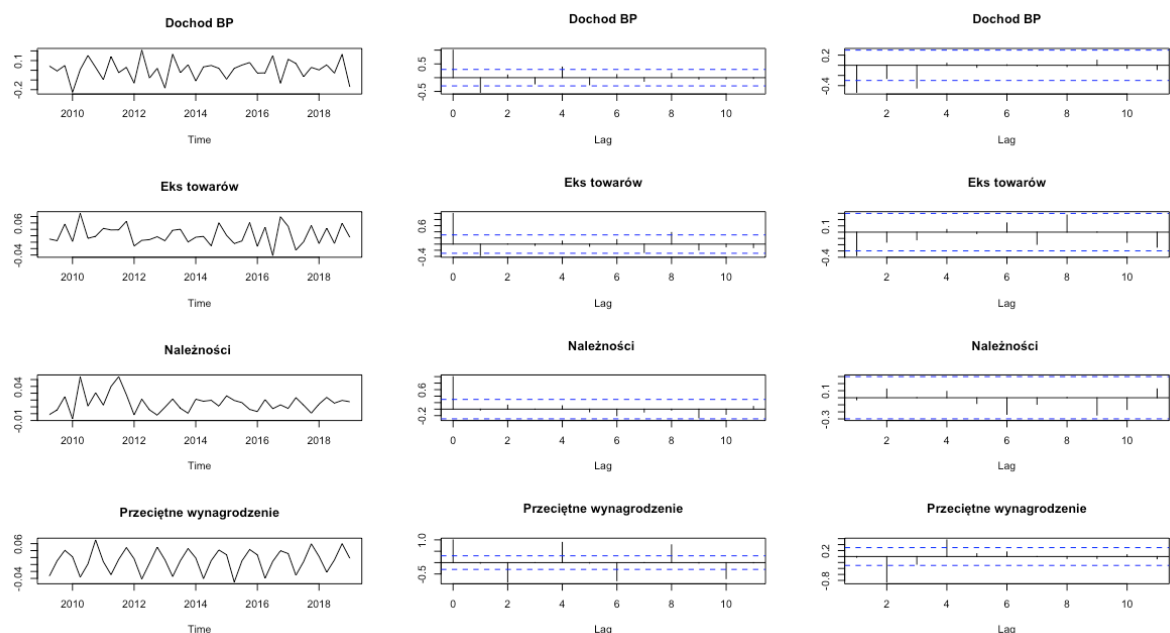


Analiza wykresów:

- Dochody budżetu państwa: wykres ACF zbiega w wolnym tempie do 0, nie urywa się, co wskazuje na proces AR oraz mamy brak stacjonarności, natomiast z wykresu PACF wskazuje na liczbę opóźnień 5. Do roku 2016 stały/średni poziom, natomiast po 2016 roku widzimy trend.
- Eksport towarów: wykres ACF zbiega w wolnym tempie do 0 nie urywa się, co wskazuje na proces AR i brak stacjonarności, natomiast z wykresu PACF wskazuje na liczbę opóźnień 1. Trend
- Należności ogółem: wykres ACF zbiega w wolnym tempie do 0, nie urywa się co wskazuje na proces AR i brak stacjonarności, natomiast z wykresu PACF wskazuje na liczbę opóźnień 1. Trend
- Przeciętne wynagrodzenia: wykres ACF zbiega w wolnym tempie do 0, nie urywa się co wskazuje na proces AR i brak stacjonarności, natomiast z wykresu PACF wskazuje na liczbę opóźnień 1. Trend + sezonowość

Analiza wykresów ACF i PACF wskazuje na proces AR z liczbą opóźnień równą $k_{max}=5$.

Przejdźmy do analizy przyrostów.



Stopnie opóźnień wybieramy na podstawie poziomów, natomiast wykresy przyrostów służą do zbadania stacjonarności.

- Dochody budżetu państwa: Poprawi się stacjonarność. Słupki mieszczą się w poziomie istotności.
- Eksport towarów: wskazuje na poprawę stacjonarności, natomiast widzimy, że w ósmym opóźnieniu mamy wybiecie poza przedział ufności.
- Należności ogółem: Poprawiła się stacjonarność.
- Przeciętne wynagrodzenia: Widoczna sezonowość. Po uwzględnieniu sezonowości, nie powinno być problemów ze stacjonarnością.




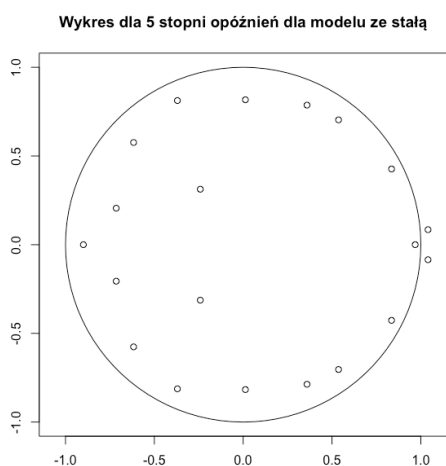
Następnie korzystając z kryteriów informacyjnych wyznaczam liczbę stopni opóźnień, ustalając maksymalną liczbę opóźnień równą 5. Rozważam dwie grupy modeli, jeden ze stałą, a drugi z trendem liniowym. Zarówno dla modelu z trendem liniowym, jak i modelu ze stałą kryteria informacyjne dają takie same stopnie opóźnień:

Kryterium	AIC	HQ	SC	FPE
St. opóźnień	5	5	1	5

Rozważamy szereg z 40 obserwacjami zatem wybieramy stopnie opóźnień $k_{max} = 5$ oraz $k_{max} = 2$. Nie wybieramy $k_{max} = 1$ jak podają kryteria informacyjne z powodu tego, że w momencie przejścia na przyrosty pozostaje tylko biały szum. Rozważając szereg z większą ilością

obserwacji, jeśli w takiej analizie trzy kryteria dają ustaloną maksymalną liczbę stopni opóźnień, należałoby zwiększyć tę liczbę.


Dla wybranych rzędów sprawdzono stabilność licząc wartości modułów dla wartości własnych macierzy stowarzyszonej. Na poniższych rysunkach widzimy, że dla dwóch i pięciu stopni opóźnień, zarówno dla modelu ze stałą, jak i modelu z trendem liniowym występują wartości własne macierzy stowarzyszonych znajdujące się poza okręgiem jednostkowym. Wskazuje to na brak stabilności dla poziomów.




W kolejnym kroku badamy stacjonarność dla przyrostów. Stopnie opóźnień zmniejszamy z pięciu na cztery oraz z dwóch na jeden, natomiast model ze z trendem liniowym zmieniamy na model ze stałą a model ze stałą na model z brakiem składowej deterministycznej.

Model ze stałą jak model bez składowej deterministycznej z czterema stopniami opóźnień nadal nie wykazuje stabilności, co widać na poniższych rysunkach.

Wykres dla 4 stopni opóźnień dla modelu bez składowej deterministycznej




Wykres dla 4 stopni opóźnień dla modelu ze stałą




Model dla jednego stopnia opóźnień zarówno dla modelu ze stałą jak i modelu bez składowej deterministycznej wykazuje stabilność, ponieważ wartości własne macierzy stowarzyszonej są wewnątrz koła.

Wykres dla 1 stopnia opóźnień dla modelu bez składowej deterministycznej



Wykres dla 1 stopnia opóźnień dla modelu ze stałą



Biorąc pod uwagę warunek stabilności wybieramy model VAR rzędu 1 ze stałą deterministyczną oraz bez składowej deterministycznej i wykonujemy test restrykcji zerowych dla modeli: VAR rzędu 1 ze stałą deterministyczną oraz bez składowej deterministycznej. Po przeprowadzeniu testu restrykcji zerowych wybieramy model z jednym opóźnieniem i stałą składową deterministyczną. Dla wybranego modelu przeprowadzono testy białoszumowości, czyli braku autokorelacji składników losowych. Zarówno w teście Lagrange'a jak i teście walizkowym, w którym testowano 11 macierzy korelacji, otrzymujemy na poziomie istotności $p = 0,1$, że nie ma podstaw do odrzucenia hipotezy o białoszumowości. Po wykonaniu testu

normalności reszt wielorównaniono jak i dla każdego równania otrzymujemy p-value istotnie większe od zera, zatem nie ma problemu z normalnością reszt.

Teraz dokonamy testu Johansena w celu określenia liczby relacji kointegrujących. Test dany jest w dwóch postaciach: maksymalnej wartości własnej oraz test śladu dokonując. Dla maksymalnej wartości własnej stawiamy hipotezę:

$$H_0: r = 0 \vee H_1: r = 1$$

Na poziomie istotności 0.01,0.05,0.1 została odrzucona hipoteza H_0 . Idąc dalej stawiamy hipotezy:

$$H_0: r = 1 \vee H_1: r = 2$$

Tutaj na poziomie istotności 0.01 odrzucamy hipotezę H_0 i stawiamy następujące hipotezy

$$H_0: r = 2 \vee H_1: r = 3$$


Na dowolnym poziomie istotności nie mamy podstaw do odrzucenia hipotezy H_0 dopiero dla $r = 3$. Zatem otrzymujemy między 2 a 3 relacji długookresowych. Wykonując test śladu pierwsza z postawionych hipotez wygląda następująco:

$$H_0: r = 0 \vee H_1: r \geq 1$$

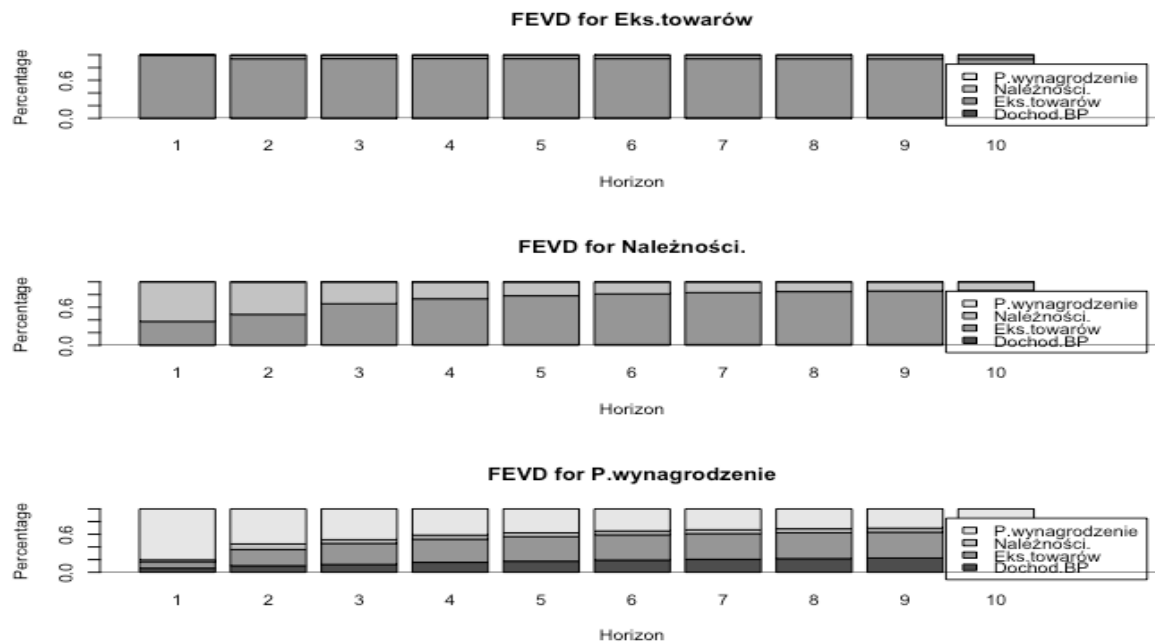
Po przeprowadzeniu testu otrzymujemy poziomie istotności nie mamy podstaw do odrzucenia hipotezy H_0 dopiero dla $r = 3$. Podobnie jak w teście maksymalnej wartości własnej mamy między 2 a 3 relacje długookresowe. Przyjmujemy w module, że mam trzy relacje długookresowe ($r = 3$). Analizując kolumny współczynniki dostosować zmiennych do relacji, otrzymujemy:

- Dochód BP dostosowuje się do pierwszej relacji,
- Eksport towarów nie dostosowuje się do żadnej relacji,
- Należności dostosowują się drugiej i trzeciej relacji,
- Przeciętne wynagrodzenie dostosowuje się do trzech relacji.

Przechodząc do interpretacji wybranego wykresu IRF otrzymujemy, że wstrząs w eksporcie towarów wpływa na wzrost dochodów państwa w pierwszym okresie, a następnie występuje korekta i stabilizacja na poziomie wyższym niż bazowy. Jest to zgodne z intuicją, ponieważ przeciębiorstwa więcej sprzedają, czyli większy podatek odprowadzają do państwa. Wstrząs w Eksporcie towarów powoduje wzrost i ustalenie na wyższym poziomie należności. Jest to zgodne z intuicją, ponieważ jeśli zwiększymy eksport towarów, to zwiększą się należności. Podobnie wstrząs eksportu towarów prowadzi do ustalenia się przeciętnego wynagrodzenia na wyższym poziomie.




Dalej porównamy wariancję prognozy błędu. Dla wyjaśnienia błędu prognozy Eksportu towarów widzimy, że wstrząs z równania własnego dominuje we wszystkich okresach. Oznacza to, że blisko 98% niepewności prognozy jest wyjaśnione własnymi zaburzeniami, niezależnie od długości prognozy. Dla wahliwości wyjaśniania prognozy Należności o horyzoncie jeden w 30% wyjaśniana jest Eksportem towarów a 70% Należnościami. W drugim okresie mamy już podział 50% wyjaśnienia Eksportem towarów a 50 % Należnościami, natomiast od trzeciego okresu do piątego okresy rośnie Eksport Towarów a maleją Należności by od piątego do dziesiątego okresu się ustabilizować na poziomie 85 % dla Eksportu towarów i 20 % dla Należności. W wyjaśnieniu prognozy Przeciętnego wynagrodzenia w pierwszych trzech horyzoncie najważniejsze jest ona sama, lecz ma tendencję malejącą a pozostałe zmienne mają tendencję rosnącą. Natomiast od czwartego do dziesiątego horyzontu mamy niemalże równy podział: Dla wahliwości prognozy Przeciętnego Wynagrodzenia ok. 50 % wpływu mają własne zaburzenia, 30 % zaburzenia związane z Eksportem towarów, 20% zaburzenia związane z Dochodem BP a 10 % zaburzenia związane z Należnościami.



Po wyznaczeniu ścieżek prognoz z horyzontem 8 na wykresach zauważamy:


- Dochód BP widzimy, że początkowo spadnie, następnie jego wartość przewyższy maksymalną wartość, którą mają dane historyczne. Następnie wystąpi spadek i wzrost. W przestrzeni czasowej 8 horyzontów zauważyć można trend.

Fanchart for variable Dochod.BP




- Eksport towarów zauważamy, naprzemienne wzrosty i spadki prognozy. W przestrzeni czasowej 8 horyzontów zauważyć można trend.

Fanchart for variable Eks.towarów




- Należności początkowo utrzymuje się na stałym poziomie a następnie rośnie. W przestrzeni czasowej 8 horyzontów zauważyć można trend.

Fanchart for variable Należności.



- Przeciętne wynagrodzenia, prognoza oddaje sezonowości, która występuje w danych.
W przestrzeni czasowej 8 horyzontów zauważyć można trend.

Fanchart for variable P.wynagrodzenie



W przypadku Przeciętnego Wynagrodzenia prognoza oddaje sezonowość oraz z biegiem czasu prognoza jest pewna, ponieważ zakresy prognoz się nie rozszerzają i nie tworzą charakterystycznego kształtu wachlarza.

Podsumowanie

Przeprowadzone badania pokazują, że między analizowanymi zmiennymi istnieją zależności o charakterze przyczynowym. Stąd do krótkookresowego prognozowania wykorzystano wektorowe modele autoregresji (VAR) oraz wektorowe modele korekty błędem (VECM). Modele te, mają dość uniwersalny charakter i pozwalają na wychwycenie zarówno prawidłowości występujących w szeregach czasowych jak i interakcji między analizowanymi zmiennymi. Z badań wynika, że analizowane szeregi czasowe charakteryzują się dużą zmiennością; trend oraz sezonowość, wahania cykliczne. Przeprowadzone analizy pokazały, zależności między zmiennymi. Największe zależności zauważyć można w prognozowaniu przeciętnego wynagrodzenia, które prognoza zależy od pozostałym zmiennych jak i samej zmiennej prognozowanej.